

INTRODUCCIÓN AL ANÁLISIS DE DATOS

Prof. Natalia Lucero

Clase n° 2



¿POR QUÉ DEBERÍA HACER UN ANÁLISIS EXPLORATORIO DE DATOS?

Razones para
realizar un
análisis
exploratorio
de datos



ORGANIZAR Y ENTENDER LAS VARIABLES:

- Identificar los distintos tipos de variables (categóricas, continuas, etc.).
- Determinar qué tipo de análisis puedes realizar con ellas.



ESTABLECER RELACIONES ENTRE VARIABLES:

- Descubrir si las variables cambian al analizarse juntas.
- Identificar asociaciones o patrones ocultos en los datos que podrían pasar desapercibidos.




Seleccionar el modelo adecuado

- Un AED te ayuda a identificar qué variables son útiles y cómo están relacionadas.
- Esto evita construir modelos deficientes y asegura que el modelo seleccionado sea el más adecuado para la tarea.



Tomar decisiones fundamentadas:

- Las decisiones basadas en datos son más confiables.
- Un AED te permite fundamentar tus decisiones en patrones, relaciones y análisis sólidos.



PASOS PARA REALIZAR UN ANÁLISIS EXPLORATORIO DE DATOS



El proceso de un AED puede dividirse en cinco pasos principales:

- Hacer preguntas sobre la base de datos y las preguntas que guían tu análisis exploratorio
- Determinar el tamaño de los datos.
- Categorizar las variables
- Limpieza y validación de datos
- Establecer relaciones entre los datos

1. HACER PREGUNTAS

- Define qué quieres descubrir en los datos:
¿Qué información necesitas?
¿Qué preguntas quieres responder?
¿Cuál es el objetivo de tu análisis?



Determinar el tamaño de los datos



- Analiza la cantidad de observaciones y variables:
 - ¿Cuántas observaciones existen?
 - ¿Cuántas variables hay?
 - ¿Existen datos que puedes eliminar por ser irrelevantes?

Categorizar las variables

- Clasifica las variables según su tipo:
¿Cuántas son categóricas? ¿Cuántas son continuas?
¿Qué métodos de análisis son más adecuados según cada categoría?



Limpieza y validación de datos

- Asegúrate de que los datos estén en buen estado:
 - ¿Hay datos faltantes? Si es así, ¿cómo los manejarás?
 - ¿Existen valores anómalos que debas tratar?
 - Analiza la proporción y distribución de los datos.



Establecer relaciones entre variables

- Examina cómo las variables interactúan entre sí:
 - ¿Existe relación entre la variable X y la Y?
 - ¿Qué sucede al considerar otras variables como Z?
- Identifica patrones y agrupaciones en los datos.



UN PROCESO CÍCLICO, PERO CON UN FINAL



El análisis exploratorio de datos no es lineal, sino cíclico. Esto significa que:

Comenzarás formulando preguntas.

Ajustarás los datos (tamaño, limpieza, categorización).

Identificarás relaciones entre las variables.

Luego, repetirás el ciclo con nuevas preguntas y ajustes. Sin embargo, es crucial saber cuándo detenerte. Un AED interminable no genera resultados útiles, así que debes decidir cuándo es suficiente para avanzar y compartir tus hallazgos.

- EL PROCESO DE REALIZAR UN ANÁLISIS EXPLORATORIO DE DATOS (EDA) PUEDE VARIAR DEPENDIENDO DEL TIPO DE DATOS Y DE LOS OBJETIVOS ESPECÍFICOS DEL ANÁLISIS, PERO EN GENERAL, EL EDA SIGUE LOS SIGUIENTES PASOS BÁSICOS:



Importación y limpieza de datos:

- Antes de realizar cualquier análisis, es importante asegurarse de que los datos estén en un formato adecuado y limpio. Esto puede incluir la eliminación de valores perdidos, la corrección de valores inconsistentes y la transformación de variables si es necesario.




Análisis univariado:

- Este tipo de análisis se enfoca en una sola variable a la vez. Por ejemplo, se puede calcular la media, la desviación estándar, el rango y la distribución de una variable. También se pueden crear gráficos de barras, histogramas, gráficos de densidad, entre otros, para visualizar la distribución de la variable.



Análisis bivariado:

- En este tipo de análisis, se estudian dos variables simultáneamente. Se pueden crear gráficos de dispersión, matrices de diagramación de pares, y se pueden calcular medidas de correlación para explorar la relación entre las dos variables.



Análisis multivariado:

- En este tipo de análisis, se estudian varias variables a la vez. Se pueden realizar técnicas como los componentes principales, la agrupación (clustering) y la reducción de dimensionalidad para identificar patrones y tendencias en los datos.



Visualización y comunicación de resultados:

- Una vez realizado el análisis, es importante visualizar y comunicar los resultados de manera clara y concisa. Esto puede incluir la creación de gráficos, tablas y resúmenes para presentar los resultados.



- Es importante destacar que el EDA es un proceso iterativo, lo que significa que puede ser necesario volver a revisar los datos y ajustar el análisis en función de los hallazgos. Además, el EDA no es un proceso lineal y es posible que se salten algunos pasos o se realice un análisis más detallado en función de los datos y objetivos específicos del proyecto.



POO

- El concepto de POO se puede aplicar a cualquier lenguaje de programación y que soporte su paradigma.




Objetos

- Dentro de la POO y retomando lo visto en la clase anterior mencionamos que tenemos objetos.
- Decimos que un OBJETO dentro de la POO se lo conoce como CLASE
- Esto quiere decir que ambos son objetos.




Copias de Objetos



¿Qué pasa cuando nosotros le sacamos una copia a una clase?

- Vamos a obtener una copia de un objeto.
- Cada copia que nosotros hagamos de un objeto va a ser un objeto a las cuales llamaremos INSTANCIAS

Instancia



- Decimos entonces que cada vez que realizamos una copia a una clase, ésta será una copia de un molde o plantilla de mi clase . A esto llamamos INSTANCIA.
- Podemos cargar en ella los atributos de la plantilla original.
- Cada copia será una instancia de la clase y todas las clases que podemos definir van a tener su copia , ósea todas las instancias que podemos tener dentro de un proyecto.


Por ejemplo:

- Tenemos la CLASE USUARIO donde vemos que tiene 5 atributos (nombre, apellido, correo, contraseña y teléfono)
- También tiene 3 métodos (encriptar contraseña, verificar contraseña y obtener por correo)



Iniciando INSTANCIAS

- Cuando creamos una copia de nuestra plantilla original de usuario , podemos conservar el nombre pero añadiremos algunos cambios. Por ejemplo:
- Usuario 1
- En caso de necesitar más copias puedo seguir utilizando el mismo nombre pero variando.



Importante!

- Es importante saber que cada instancia tendrá los mismos atributos o datos que la clase usuario y los mismos métodos o funcionalidades que la clase que se utilizó como plantilla o molde.




Otro ejemplo sería :

- `mi_coche = Coche("Toyota", "Corolla")`
- `print(mi_coche.describir())` # Salida: Este coche es un Toyota Corolla
- En el ejemplo 'Coche', 'marca' y 'modelo' son atributos, mientras que 'describir()' es un método.



Los 4 Pilares de la POO



Abstracción:

- Si bien una clase puede tener infinitos atributos, la abstracción se basa en elegir los atributos más importantes o la información de nuestra clase que vamos a manipular.




Por ejemplo:

- Si retomamos el ejemplo de la CLASE USUARIO, lo que nos permite la abstracción es sólo enfocarnos en lo más importante tanto en las características como en los métodos que son importantes en nuestros objetos.



- Los atributos relevantes o más importantes serian: nombre, apellido, correo, contraseña y teléfono.
- Los atributos no tan importantes serian: color-piel, estatura y lunares.



- Lo mismo pasa con el método : lo más importante seria encriptar contraseña, verificar contraseñas y obtener por correo
- Utilizar un método sin sentido no tendría relevancia en nuestra clase.



Actividades:

- 1- Realizar cuestionario para asistencia
- 2- Actividad 1: Análisis Exploratorio de Datos: (En grupo)

Consigna:

Observa la siguiente tabla con información de 5 alumnos:

Nombre	Edad	Nota	Carrera
Ana	20	8	Sistemas
Juan	22	6	Diseño
Carla	21	9	Sistemas
Pedro	23	5	Marketing
Sofía	20	7	Sistemas

Tareas:

1. Indica qué variables son **categorías** y cuáles son **numéricas**.
2. Calcula el **promedio de la columna Nota**.
3. Cuenta cuántos alumnos pertenecen a la carrera **Sistemas**.
4. ¿Qué estudiante tiene la **mayor nota**?

Actividad 2: POO (en grupo)

Consigna:

Queremos representar a un **auto** en un programa.

Tareas:

1. Define una **clase Auto** con los atributos: marca y color.
2. Crea **dos objetos** de la clase Auto (por ejemplo: un Ford rojo y un Toyota azul).
3. Muestra en pantalla el color y la marca de cada auto.
4. Explica con tus palabras qué es una **instancia**.